

Analyse Comportementale Clientèle Retail

Prédiction du Churn par Machine Learning

 Atelier Pratique E-commerce de Cadeaux · Module GI2

 Préparée par : Eya Hadj Abdallah

 Encadrante : Mme Fadoua Drira



Exploration



Préparation



Modélisation



Évaluation



Déploiement

Contexte & Problématique

 **Contexte e-commerce de cadeaux** : 4 372 clients analysés à travers 52 variables (données volontairement imparfaites).

PROBLÉMATIQUE CENTRALE

« Comment identifier, à partir des données transactionnelles et comportementales, les clients à risque de churn afin de déclencher des actions de fidélisation ciblées ? »



1. Segmenter

Diviser la clientèle en groupes homogènes selon leur comportement d'achat global.



2. Prédire le Churn

Identifier proactivement les profils de clients susceptibles de quitter la plateforme.



3. Prédire la Valeur

Estimer le potentiel financier futur et la Life-Time Value de chaque client.



Enjeu métier majeur : Acquérir un nouveau client coûte 5 à 7× plus cher que le fidéliser.

Description des données



4 372

Clients uniques



52

Features disponibles



Churn

Cible binaire (0/1)

Catégorie de Variables	Exemples de Features
Variables RFM	Recency , Frequency , MonetaryTotal
Comportementales	PreferredMonth , FavoriteSeason , UniqueProducts
Catégorielles	Region , Gender , Country , ProductDiversity
Qualité & Service Client	SupportTickets , SatisfactionScore , ReturnRatio



POINT CLÉ : DÉSÉQUILIBRE DES CLASSES

La variable cible présente un fort déséquilibre avec **67% de clients fidèles** contre **33% de churners**.

→ Cette asymétrie a été traitée lors de la modélisation via la méthode **SMOTE** (Synthetic Minority Over-sampling Technique) pour éviter un biais prédictif.

Problèmes de qualité & nettoyage

Type de Problème	Features concernées	Ampleur	Traitement appliqué
 Valeurs manquantes	Age	30%	Imputation médiane (sur train uniquement)
 Valeurs aberrantes	SupportTickets (999, -1) SatisfactionScore (99, -1)	Cas isolés	Remplacement par NaN puis imputation robuste
 Formats inconsistants	RegistrationDate (UK / ISO / US)	Multiple formats	<code>pd.to_datetime(dayfirst=True)</code>
 Sans variance	NewsletterSubscribed	Toujours "Yes"	 Suppression de la variable
 IP brute	LastLoginIP	Hétérogène	Transformation en booléen <code>IsPrivateIP</code>
 Multicolinéarité	MonetaryMin ↔ MonetaryStd	$r = 0,97$	 Suppression des variables avec VIF > 10

Encodage des variables catégorielles

Transformation des données textuelles en format numérique pour le Machine Learning



Encodage Ordinal

Variables avec ordre naturel

UTILISATION

- Variables avec relation d'ordre
- Catégories hiérarchiques

EXEMPLES

- **AgeCategory:** 18-24 < 25-34 < 35-44
- **BasketSizeCategory:** Petit < Moyen
- **PreferredTimeOfDay:** Matin < Soir

TECHNIQUE

```
OrdinalEncoder()
```



Encodage One-Hot

Variables nominales sans ordre

UTILISATION

- Variables sans relation d'ordre
- Catégories indépendantes

EXEMPLES

- **FavoriteSeason:** Printemps, Été...
- **Region:** Nord, Sud, Est, Ouest
- **Gender:** M, F, Non-binaire
- **ProductDiversity:** High, Medium...

TECHNIQUE

```
pd.get_dummies()  
OneHotEncoder()
```



One-Hot Différé

Pour Country (37+ modalités)

PARTICULARITÉ

- 37+ modalités (pays)
- Appliqué après split train/test
- Évite la fuite de données

CONFIGURATION

```
handle_unknown='ignore'  
fit sur train uniquement
```

⚠ L'encodage de Country est réalisé **APRÈS** le split train/test pour ne pas contaminer l'entraînement avec des informations du test.



Note importante: Toutes les transformations sont "fit" sur l'ensemble d'entraînement uniquement, puis "transform" sur l'ensemble de test pour éviter la fuite de données.

Feature Engineering & Data Leakage

√x Feature Engineering

Intensité d'Achat (Dépense journalière)

$\text{MonetaryPerDay} = \text{MonetaryTotal} / (\text{Recency} + 1)$

Valeur Panier Moyen

$\text{AvgBasketValue} = \text{MonetaryTotal} / \text{Frequency}$

Ratio de Rétention

$\text{TenureRatio} = \text{Recency} / (\text{CustomerTenureDays} + 1)$

⚠ Alerte : Data Leakage

🔊 **Symptôme** : Modèle Random Forest initial atteignant une **accuracy de 100%** (score trop parfait, suspect en conditions réelles).

🔍 **Cause** : Présence de **17 colonnes** directement dérivées de la variable cible *Churn* (informations futures inconnues lors de la prédiction).

🗑 **Action (Suppression)** : `ChurnRiskCategory`, `CustomerType`, `LoyaltyLevel`, `RFMSegment`, `AccountStatus`, `ReturnRatio`, `NegQtyCount`, `ZeroPriceCount`, `CancelledTransactions`, `Recency` (r=0,86)...

📈 **Résultat** : L'accuracy tombe à **94,5%**, reflétant la véritable performance généralisable du modèle.




« La chute de 100% à 94,5% n'est pas une dégradation, c'est une **CORRECTION INDISPENSABLE** pour assurer l'utilité métier du modèle. »

ACP & Clustering K-Means


⚡ Réduction ACP

- **87 variables** réduites à **56 composantes** principales.
- Conserve **95,5% de la variance** totale des données.
- **Bénéfices** : réduction du bruit, temps de calcul accéléré, évite la malédiction de la dimensionnalité.



🔗 Clustering K-Means

- Appliqué de manière optimale sur les **56 composantes ACP**.
- Méthode du coude + Silhouette => **K=4 optimal**.
- **Score de silhouette : 0.086** (nette amélioration par rapport à 0.038 sans ACP).



Segment Identifié		Effectif	Proportion	Profil & Recommandation
A	Clients Premium	1 453	33,2%	Haute fréquence d'achat, montant total très élevé. Cœur de cible à récompenser.
B	Clients Réguliers	884	20,2%	Achats stables et réguliers. Profil sain à consolider via le cross-selling.
C	Clients Occasionnels	928	21,2%	Achats ponctuels (saisonniers). Fort potentiel de réactivation promotionnelle.
D	Clients Inactifs	232	5,3%	Faible engagement. Risque très élevé de churn (ou déjà churners).

Random Forest — Résultats de classification



Principe de l'algorithme

Ensemble de **1000 arbres de décision**, mécanisme de vote majoritaire, intégrant le **bagging** et le **feature subsampling** pour réduire la variance.



Pipeline de Modélisation

SMOTE (ratio 0,5) → RandomizedSearchCV

(60 combinaisons, 5 plis) → Optimisation du seuil

📊 Résultats de Classification (Test)	
Accuracy (Précision globale)	94,5%
Précision (Churner)	0,94
Rappel (Identification des risques)	0,89
F1-Score	0,92
AUC (Aire sous la courbe)	0,985



Meilleurs Hyperparamètres

n_estimators

1000

max_depth

40

min_samples_leaf


3

max_features

0,7

⚡ Seuil optimisé : 0,47

F1 = 0,929



XGBoost — Résultats de classification

⚡ Principe de l'algorithme

Boosting itératif : chaque arbre corrige les erreurs du précédent. Intègre une **régularisation L1/L2** native pour limiter le surapprentissage.

⚙️ Pipeline de Modélisation

SMOTE (ratio 0,5) → GridSearchCV (5 plis)
→ Optimisation du seuil sur l'intervalle [0,30 ; 0,70]

🔧 Meilleurs Hyperparamètres

n_estimators 700 max_depth 5 learning_rate 0,03
subsample 0,8 colsample_bytree 0,9


⚡ Seuil optimisé : 0,60 (Maximise l'accuracy)

Pourquoi 0,60 ? Réduit les faux positifs, augmente la précision pour les churners.

📊 Résultats de Classification (Test)

Accuracy (Précision globale)	97,1%
Précision (Churner)	0,99
Rappel (Identification des risques)	0,92
F1-Score	0,96
AUC	0.,994

Matrice de confusion - XGBoost



Stacking & Importance des features

Architecture du Stacking (3 Niveaux)

- Niveau 0 : Modèles de base (Random Forest + XGBoost)
- Méta-features : Probabilités obtenues en validation croisée (5 plis)
- Niveau 1 : Méta-modèle (Régression Logistique)

Poids du méta-modèle : XGB = 5,82 vs RF = 2,52

Accuracy Globale : 97,0%


Top Features & Interprétation

FavoriteSeason_Automne PreferredMonth ProductDiversity_Explorateur
UniqueProducts


Insights Métier

- Les achats saisonniers (ex: automne) témoignent d'une fidélité plus faible.
- Les "explorateurs" sans catégorie fixe sont plus vulnérables au churn.


Matrice de confusion - Stacking






Top 15 features importantes - Random Forest



Top 15 features importantes - XGBoost



Courbes ROC comparatives – Random Forest, XGBoost, Stacking



Régression & Comparaison des modèles

XGBoost Regressor : Prédiction de MonetaryTotal

Problème (Régression Linéaire)


Distribution asymétrique. $R^2 = 0,390$ | RMSE = 8 860£

Solution

XGBoost Regressor + RandomizedSearchCV (30 itérations)

Résultats après optimisation

- $R^2 = 0,545$ (+39,7%)
- RMSE = 7 648£ (-13,7%)
- MAE = 5 520£ (-14,4%)



Comparaison des Classifieurs

Random Forest

Accuracy : **94,5%** Rappel : **0,89** F1 : **0,92** Seuil : **0,47**

XGBoost ★

Accuracy : **97,1%** Rappel : **0,92** F1 : **0,96** Seuil : **0,60**


Stacking (Ensemble)

Accuracy : **97,0%** Rappel : **0,93** F1 : **0,95** Seuil : **0,50**

 Le modèle **XGBoost** est retenu comme modèle final pour le déploiement grâce à son excellent équilibre entre l'Accuracy globale et l'identification précise des churners.

Déploiement Flask

Architecture du Pipeline de Déploiement




Fonctionnalités de l'Interface

- 1 **Prédiction du churn (Fidèle/Churner)** pour les 3 classifieurs (RF, XGBoost, Stacking) avec affichage des probabilités.
- 2 Attribution du **Segment K-Means** (Profils A, B, C, ou D).
- 3 **Montant total estimé** généré par le modèle XGBoost Regressor.
- 4 **Dashboard global** présentant l'ensemble des métriques prédictives en temps réel.
- 5 **Graphique d'importance des features** dynamique et interactif propulsé par Chart.js.

 **Accessible sans compétence technique — permet de prédire les risques et valeurs en temps réel pour tout profil client.**

Modèles Sérialisés (.pkl)

random_forest.pkl xgboost.pkl stacking.pkl
kmeans.pkl pca.pkl regression_xgboost_optimized.pkl



Conclusion & Perspectives

Bilan des réalisations

- ✓ **Correction du data leakage** : 100% → 94,5% (Random Forest)
- ✓ **XGBoost** : accuracy 97,1%, F1-score 0,96, identifie 92% des churners
- ✓ **Régression améliorée** : R^2 0,390 → 0,545 (XGBoost Regressor)
- ✓ **Clustering enrichi par ACP** : silhouette 0,038 → 0,086
- ✓ **Application Flask** : vision complète client (churn + segment + valeur)

Recommandations métier

- 🔗 Déployer **XGBoost (seuil 0,60)** pour cibler les clients à risque
- 🍂 Lancer des campagnes de rétention **avant l'automne** (feature clé)

- 👑 Créer un programme fidélité spécifique aux **clients Premium (Segment A)**
- 🚚 Déclencher une **réactivation urgente** pour le Segment D (Inactifs)

Perspectives techniques futures

⚡ LightGBM / TabNet

🚢 Docker & Gunicorn

🔗 Pipeline MLOps (MLflow)

📊 Monitoring Data Drift